

UNIVERSIDADE PRESBITERIANA MACKENZIE

PATRIC FERREIRA DA SILVA

**USO DE REDE DE KOHONEN PARA A
CLUSTERIZAÇÃO DE OBJETOS DE
APRENDIZAGEM**

São Paulo
2007

PATRIC FERREIRA DA SILVA

USO DE REDE DE KOHONEN PARA A CLUSTERIZAÇÃO DE OBJETOS DE APRENDIZAGEM

Dissertação apresentada ao
Programa de Pós-Graduação em
Engenharia Elétrica da Universidade
Presbiteriana Mackenzie como parte
dos requisitos para a obtenção do
Título de Mestre em Engenharia
Elétrica.

Orientadora: Prof^a. Dr^a. Pollyana Notargiacomo Mustaro

São Paulo
2007

S586u Silva, Patric Ferreira da.

Uso de rede de Kohonen para a clusterização de objetos de aprendizagem / Patric Ferreira da Silva – 2007.

114 f. : il. ; 30 cm.

Dissertação (Mestrado em Engenharia Elétrica) - Universidade Presbiteriana Mackenzie, São Paulo, 2007.

Bibliografia: f. 105-107.

1. Objetos de aprendizagem. 2. Clusterização. 3. Redes neurais. 4. Redes de Kohonen. 5. Mapas auto-organizáveis. 6. Inteligência artificial. I. Título.

CDD 519.535

PATRIC FERREIRA DA SILVA

USO DE REDE DE KOHONEN PARA A CLUSTERIZAÇÃO DE OBJETOS DE APRENDIZAGEM

Dissertação apresentada ao
Programa de Pós-Graduação em
Engenharia Elétrica da Universidade
Presbiteriana Mackenzie como parte
dos requisitos para a obtenção do
Título de Mestre em Engenharia
Elétrica.

Aprovado em: São Paulo, de de 2007.

BANCA EXAMINADORA

Prof^a. Dr^a. Pollyana Notargiacomo Mustaro – Orientadora
Universidade Presbiteriana Mackenzie

Prof. Dr. Luiz Henrique Alves Monteiro
Universidade Presbiteriana Mackenzie

Prof. Dr. Vagner Bernal Barbeto
Centro Universitário da FEI

À minha amada esposa Márcia, com
gratidão pelo seu amor e incansável
apoio ao longo deste trabalho.
À minha querida filha Júlia, pelo
carinho e compreensão.

AGRADECIMENTOS

Primeiramente a Deus, que permitiu a elaboração desta pesquisa.

Aos meus pais, Edson e Olga, que não tiveram igual oportunidade, mas me proporcionaram condições intelectuais e emocionais para o meu desenvolvimento.

À minha irmã Amanda, que apesar de todos os quilômetros de distância, sempre foi um exemplo de vontade.

À minha esposa Márcia, por seu apoio e incentivo constante, mesmo nos momentos mais difíceis.

À minha filha Júlia, que mesmo nos momentos ausentes me deu amor, carinho e incentivo.

À Prof^a. Dr^a. Pollyana Notargiacomo Mustaro, que me indicou esta área de pesquisa e contribuiu de forma singular com a sua orientação e para a publicação de artigos científicos. Além de sua amizade e presença constante.

À instituição de fomento CAPES e ao Instituto Presbiteriano Mackenzie, pelo apoio financeiro.

À Universidade Presbiteriana Mackenzie na pessoa do Coordenador do Programa de Pós-Graduação *Stricto Sensu* em Engenharia Elétrica Prof. Dr. Nizam Omar pela oportunidade de realização do curso de Mestrado em Engenharia Elétrica.

Aos amigos que cultivei nestes anos: Corrales e Fabiano.

Aos meus colegas de mestrado, que sabem como ninguém as dificuldades encontradas.

“O mundo está ao contrário e ninguém reparou”
(Nando Reis)

RESUMO

A crescente disponibilização, na Internet, de recursos educacionais digitais, denominados de objetos de aprendizagem, tem sido acompanhada da definição de padrões de indexação. Contudo, a falta de consenso sobre a caracterização de objetos de aprendizagem, bem como a diversidade de abordagens de metadados para sua classificação dificulta o processo de seleção destes elementos. Este cenário requer novas investigações que possibilitem o estabelecimento de parâmetros para a criação de um modelo específico de Rede Neural Artificial para a clusterização de objetos de aprendizagem. A implementação deste modelo vinculou-se a uma opção teórico-metodológica pautada em critérios de padrões de metadados, o que possibilitou a formação de um espaço amostral para a construção de um Mapa Auto-Organizável (Rede de Kohonen) por meio de algoritmos e modelos matemáticos. Conseqüentemente, o desenvolvimento desta proposta de clusterização de objetos de aprendizagem pode subsidiar o trabalho educacional presencial e on-line e colaborar para a reusabilidade dos objetos de aprendizagem. Foi também objeto desta pesquisa a investigação de como a máscara de pesos, um dos parâmetros da Rede de Kohonen, afeta o resultado final. Para isso foi feita uma comparação do resultado do treinamento com e sem a máscara, o que mostrou a relevância deste método para a obtenção dos resultados da presente pesquisa.

Palavras-chave: objetos de aprendizagem, clusterização, redes neurais, redes de Kohonen, mapas auto-organizáveis, inteligência artificial

ABSTRACT

The increasing availability of digital education resources in the Internet, called learning objects, has been followed by the definition of indexation standards. However, the lack of consensus about the definition of learning objects, as well the diversity of metadata approaches for its classification hinders the selection process of these elements. This scenery requires new investigations that make possible the establishment of parameters for the creation of a specific model of artificial neural network for the learning objects clustering. The implementation of this model is linked to a theoretical-methodological option, based on standard metadata criteria, which makes possible the formation of input samples for the construction of a Self-Organizing Maps (Kohonen model) through algorithms and mathematical models. Consequently, the development of this learning objects clustering proposal can subsidize the educational work in presential and on-line environments and to collaborate for the learning objects reusability. It was also object of this research the investigation of as a weight mask, one of the Kohonen model's parameters, affects the final result. For that it was made a comparison of the training result with and without the mask, showing the relevance of this method for obtaining the results of the present research.

Index Terms: learning objects, clustering, neural networks, self-organizing maps, artificial intelligence

LISTA DE FIGURAS

Figura 2-1: Exemplo de objeto de aprendizagem de funções do segundo grau.	19
Figura 2-2: Exemplo de objeto de aprendizagem de análise comportamental das funções de variados tipos.	19
Figura 3-1: Exemplo de Repositório de Objetos de Aprendizagem.	23
Figura 5-1: Estrutura das seções do neurônio.	42
Figura 5-2: Rede Acíclica de Camada Única.	44
Figura 5-3: Rede Acíclica de Camadas Múltiplas.	44
Figura 5-4: Rede Cíclica de Camadas Múltiplas.	45
Figura 5-5: Diagramas de blocos de aprendizagem supervisionada.	47
Figura 5-6: Diagrama de blocos de aprendizagem não-supervisionada.	47
Figura 5-7: Mapa Auto-Organizável de características.	49
Figura 5-8: Atualização do neurônio vencedor e da vizinhança topológica em torno do vetor de entrada x	55
Figura 5-9: Funções de taxas de aprendizagem: Linear, Exponencial, Inversa e Decaimento Exponencial, com $\eta_0=0,5$ e $T=100$	57
Figura 6-1: Formato da tabela de dados. A estrutura pode ter qualquer número de amostras, no entanto todas as amostras devem ter o mesmo número de variáveis e com o mesmo significado.	61
Figura 6-2: Estrutura hierárquica da Tabela das Áreas de Conhecimento.	63
Figura 6-3: Formação da tabela de dados de entrada da Rede de Kohonen. ...	64

Figura 7-1: Planos de componentes das variáveis Matemática, Função, Cartesiano, Linear, Quadrática, Constante e Exponencial dos dados amostrais, utilizando-se máscara padrão.	68
Figura 7-2: Planos de componentes das variáveis Logarítmica, Intrínseca, Linear, Hierárquico, Objeto, Suporte, Atualização, Construção e Simulação dos dados amostrais, utilizando-se máscara padrão.	69
Figura 7-3: Planos de componentes das variáveis Hipertextual, Orientada, Autônoma, Usabilidade, Estilos, Discussão, e Combinação dos dados amostrais, utilizando-se máscara padrão; U-Matriz e Mapa Auto-Organizável.	69
Figura 7-4: Planos de componentes das variáveis de contextualização dos dados amostrais com peso 10.	70
Figura 7-5: Planos de componentes das variáveis de contextualização dos dados amostrais com peso 20.	71
Figura 7-6: Planos de componentes das variáveis dos dados amostrais com peso 5 para a variável Cartesiano.	72
Figura 7-7: Planos de componentes das variáveis dos dados amostrais com peso 10 para a variável Cartesiano.	73
Figura 7-8: Reticulado 12x12 do Mapa Auto-Organizável com os OAs em seus respectivos neurônios após o treinamento com 1.400 épocas.	75
Figura 7-9: Reticulado 5x8 gerado automaticamente pelo SOM Toolbox. Observa-se na U-Matriz e no Mapa Auto-Organizável o número do neurônio e sua correspondente posição. Observa-se também a quantidade de OAs no mesmo neurônio.	77
Figura 7-10: Gráfico da qualidade dos reticulados avaliados.	81

Figura 7-11: Planos de componentes das variáveis Matemática, Função, Cartesiano, Linear, Quadrática, Constante, Exponencial e Logarítmica dos dados amostrais com máscara de pesos.	82
Figura 7-12: Planos de componentes das variáveis Intrínseca, Linear, Hierárquico, Objeto, Suporte, Atualização e Construção dos dados amostrais com máscara de pesos.	83
Figura 7-13 Planos de componentes das variáveis Simulação, Hipertextual, Orientada, Autônoma, Usabilidade dos dados amostrais com máscara de peso e a U-Matriz correspondente.....	83
Figura 7-14: Gráfico da qualidade dos Mapas Auto-Organizáveis com diferentes números de épocas no treinamento.....	88
Figura 7-15: U-Matriz utilizando números de épocas em uma escala de 338 até 3.500 épocas.	89
Figura 7-16: Erro de quantização da rede, utilizando-se 1.400 épocas de treinamento.....	90
Figura 7-17: Planos de componentes das variáveis Matemática, Função, Cartesiano, Linear, Quadrática, Constante, Exponencial e Logarítmica dos dados amostrais, com a rede treinada 1.400 épocas.	90
Figura 7-18: Planos de componentes das variáveis Intrínseca, Linear, Hierárquico, Objeto, Suporte, Atualização e Construção dos dados amostrais, com a rede treinada 1.400 épocas.	91
Figura 7-19: Planos de componentes das variáveis Simulação, Hipertextual, Orientada, Autônoma e Usabilidade dos dados amostrais e a U-Matriz correspondente, com a rede treinada 1.400 épocas.	91
Figura 7-20: U-Matriz e reticulado 26 x 26 do Mapa Auto-Organizável com os OAs em seus respectivos nós após o treinamento com 1.400 épocas.	92

Figura 7-21: U-Matriz e reticulado 26 x 26 do Mapa Auto-Organizável com os OAs em seus respectivos nós após o treinamento com 1.400 épocas, sem utilização da máscara de pesos..	96
--	----

LISTA DE TABELAS

Tabela 4-1: Parâmetros de Avaliação Intrínseca para Objetos de Aprendizagem.	35
Tabela 4-2: Parâmetros de Avaliação Extrínseca para Objetos de Aprendizagem.	37
Tabela 7-1: Pesos dos elementos avaliados na Tabela de Avaliação.	71
Tabela 7-2: Configuração dos reticulados avaliados com os respectivos resultados.	73
Tabela 7-3: Distribuição dos Objetos de Aprendizagem nos neurônios em reticulado 5x8.	78
Tabela 7-4: Configuração dos reticulados avaliados com os respectivos resultados.	79
Tabela 7-5: Combinações das funções de vizinhança.	85
Tabela 7-6: Resultados dos treinamentos utilizando-se os pares de funções apresentados na Tabela 7-5. Dos dezesseis pares são apresentados os oito melhores resultados (E_q menor) pela quantidade de épocas.	86
Tabela 7-7: Posição dos OAs nos respectivos neurônios após o treinamento.	93
Tabela 7-8: Grupos de OAs nos respectivos neurônios após o treinamento.	95
Tabela 7-9: Posição dos OAs nos respectivos neurônios após o treinamento sem a utilização da máscara de pesos.	97

SUMÁRIO

1	INTRODUÇÃO	16
2	OBJETOS DE APRENDIZAGEM	18
3	REPOSITÓRIOS DE OBJETOS DE APRENDIZAGEM	22
3.1	PADRÕES DE METADADOS.....	24
3.1.1	LOM.....	24
3.1.2	DublinCore	26
3.1.3	SCORM	28
3.2	ABRANGÊNCIA.....	30
3.3	DIREITOS AUTORAIS.....	30
3.4	AVALIAÇÃO	30
3.5	DOMÍNIO DO CONHECIMENTO	31
4	PARÂMETROS PARA CLUSTERIZAÇÃO DE OBJETOS DE APRENDIZAGEM	33
4.1	CARACTERÍSTICAS INTRÍNSECAS AOS OBJETOS DE APRENDIZAGEM.....	34
4.2	VALOR EDUCACIONAL DO OBJETO DE APRENDIZAGEM.....	36
5	ELEMENTOS DE REDES NEURAIS	41
5.1	REDE NEURAL ARTIFICIAL	42
5.1.1	Métodos de Aprendizado	45
5.2	REDES DE KOHONEN	48
5.2.1	Algoritmo para Mapas Auto-Organizáveis	50
5.2.1.1	Processo Competitivo	51
5.2.1.2	Processo Cooperativo.....	52
5.2.1.3	Processo Adaptativo	54
5.2.2	Estrutura do algoritmo de Kohonen	58
6	IMPLEMENTAÇÃO DE MAPAS AUTO-ORGANIZÁVEIS PARA CLUSTERIZAÇÃO DE OBJETOS DE APRENDIZAGEM	60
7	RESULTADOS	66
7.1	ETAPA COM ESPAÇO AMOSTRAL DE 17 OBJETOS DE APRENDIZAGEM.....	66

7.2 ETAPA COM ESPAÇO AMOSTRAL DE 80 OBJETOS DE APRENDIZAGEM.....	75
8 CONCLUSÃO	99
REFERÊNCIAS BIBLIOGRÁFICAS.....	102
BIBLIOGRAFIA	105
ANEXOS	108
Anexo A – Repositórios de Objetos de Aprendizagem.....	109
Anexo B –Tabela de Objetos de Aprendizagem Avaliados	110

1 INTRODUÇÃO

A sociedade contemporânea, denominada de sociedade em rede, é caracterizada pela expansão da capacidade de processamento, pelo estabelecimento de combinações diferenciadas e pela flexibilidade no que se refere à distribuição da informação (CASTELLS, 1999). Esta configuração também implica em um processo de revisão das práticas educativas, tendo em vista a disponibilização de objetos de aprendizagem (OAs) que potencializem os processos de aprendizagem.

Contudo, a exponencial disponibilização de informações por meio de redes como a Internet acarreta na crescente dificuldade de encontrar recursos educacionais pertinentes aos contextos e propostas de professores e instituições. As ferramentas atuais de pesquisa, em sua maioria, permitem apenas a busca através de palavras-chave, resultando numa grande quantidade de informação a ser filtrada manualmente. Neste contexto, para a seleção de todo o material é necessária a realização de um elevado número de buscas sucessivas para encontrar os OAs que podem ser incorporados a um curso, tornando o processo lento e muitas vezes sem efetividade.

Outro item a ser considerado são os diversos métodos de qualificação que foram criados por organizações universitárias ou governamentais. Contudo, os modos de avaliação dos OAs variam significativamente em cada instituição, o que torna inexequível a comparação das qualificações dos diversos recursos educacionais.

Por isso, este trabalho propõe o estabelecimento de parâmetros de entrada de uma Rede Neural Artificial (RNA) para a clusterização de OAs por meio de informações que podem ser recuperadas de metadados disponíveis nesses objetos. Esta proposta objetiva colaborar para ampliar a capacidade de organização e estruturação de OAs de forma a propiciar sua maior reusabilidade.

A melhoria do processo de busca, fazendo com que o mesmo se torne mais ágil, bem como a ampliação da potencialidade de aplicação educacional de OAs utilizados em um curso, pode ser realizada por meio da criação de Mapas Auto-Organizáveis (*Self Organizing Maps*), e de parâmetros avaliativos disponíveis em metadados. Baseando-se nestes métodos, torna-se possível a

clusterização de OAs por similaridade, na camada de saída da Rede Neural Artificial. Este método pode subsidiar o trabalho educacional (presencial e on-line), uma vez que possibilita aos professores a realização de pesquisa pela semelhança das características dos OAs.

Para apresentar esta proposta este documento está organizado em oito capítulos, descritos a seguir.

O capítulo 2 trata das definições, metáforas e características de OAs. O capítulo seguinte (capítulo 3) aborda os repositórios de OAs, bem como métodos e padrões de metadados como LOM, DCMI e SCORM.

No capítulo 4 são apresentados dois grupos de critérios de avaliação em uma lista de verificação que constitui uma parte da proposta de variáveis para utilização na camada da entrada da Rede Neural Artificial.

Em seguida, no capítulo 5, são discutidos elementos pertinentes à Inteligência Artificial e à Redes Neurais Artificiais, especialmente no que se refere à Rede de Kohonen.

O capítulo 6 apresenta as ferramentas de implementação da rede de Kohonen, bem como o método utilizado para a formação do espaço amostral de dados de entrada da rede.

Finalmente, no capítulo 7, são apresentados os métodos utilizados para definição dos parâmetros da rede de Kohonen, os resultados obtidos através dos parâmetros definidos durante a pesquisa e um teste utilizando uma máscara de peso com valores iguais.

Encerrando este trabalho, no capítulo 8, são apresentadas as conclusões e os trabalhos futuros pertinentes à pesquisa.

2 OBJETOS DE APRENDIZAGEM

Objeto de aprendizagem (OA), segundo a definição apresentada pelo *IEEE Learning Technology Standards Committee* (IEEE-LTSC), refere-se aos elementos digitais que podem ser utilizados, reutilizados ou mesmo referenciados ao longo do processo de aprendizagem mediado tecnologicamente (IEEE, 2003). Contudo, como esta definição é abrangente e não estabelece uma delimitação clara, pode-se criar ou encontrar OAs que variam em relação à complexidade e tamanho, indo desde um parágrafo de um texto até um curso interativo completo (LOWERISON; GALLANT; BOYD, 2003) com diferentes funções e público-alvo.

O IEEE-LTSC complementa sua definição, dizendo que aprendizado por meio tecnológico inclui sistemas computacionais de apoio à aprendizagem como ferramentas para educação a distância, sistemas para aprendizagem colaborativa e sistemas inteligentes de instrução auxiliada por computador. Segundo Sosteric e Hesemeier (2001) textos, imagens, gráficos, elementos sonoros, vídeos e demais recursos educacionais em formato digital, acompanhados de observações sobre o seu uso, podem ser considerados OAs. Assim, OAs são recursos de aprendizagem independentes que podem ser combinados a outros OAs para constituir unidades de acordo com o contexto educacional. Neste sentido, OAs podem ser tutoriais, simulações, demonstrações, modelos, estudos de caso, jogos, exercícios, testes, etc.

Na Figura 2-1 e na Figura 2-2 são apresentados dois exemplos de OAs. O primeiro é um OA interativo com exemplos práticos de funções de 2º grau, onde o usuário pode interagir através de alteração de valores e verificar a trajetória da parábola; sempre com textos explicativos. Já o segundo, permite a visualização dos gráficos de funções de vários tipos, como logarítmica, exponencial, trigonométrica, 2º grau, 3º grau, etc. sem um texto explicativo do que está ocorrendo.



Figura 2-1: Exemplo de objeto de aprendizagem de funções do segundo grau.
 Fonte: <http://www.educandus.com.br>

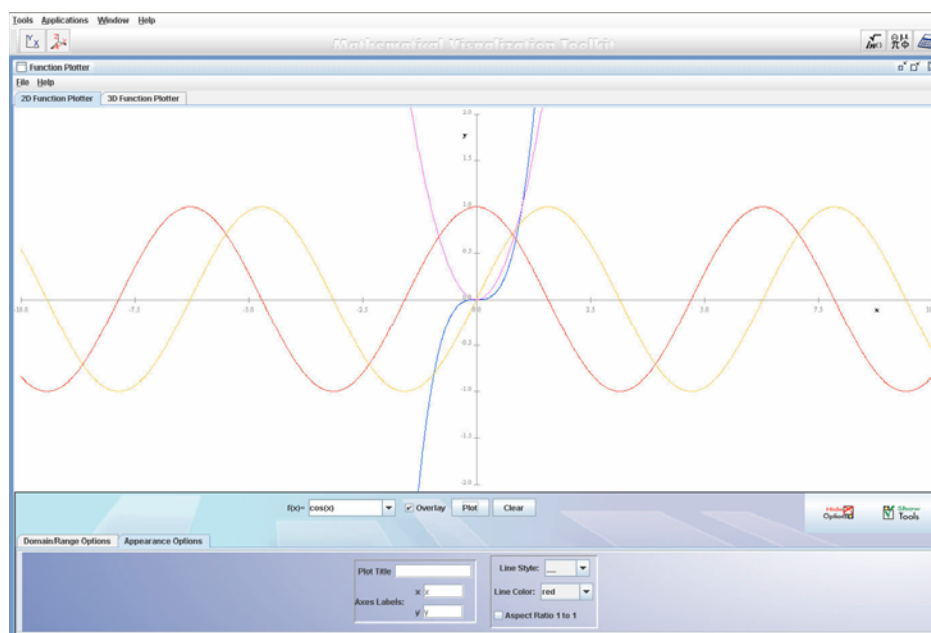


Figura 2-2: Exemplo de objeto de aprendizagem de análise comportamental das funções de variados tipos.
 Fonte: <http://amath.colorado.edu/java>

Tendo em vista a amplitude e generalidade em relação à definição de OAs, algumas metáforas estão sendo utilizadas para viabilizar a estruturação de sistemas e de propostas de uso destes elementos educacionais. As três metáforas que se destacam na literatura atual são: peças de LEGO (HODGINS, 2000), átomos / moléculas (WILEY, 2000) e organismos biológicos (PAQUETE; ROSCA, 2002). As peças de LEGO representam o conceito de reusabilidade dos OAs na medida em que permitem combinações entre as peças para a estruturação de materiais educacionais. No entanto, nem todos os OAs são combináveis entre si devido aos pré-requisitos envolvidos, estilos de aprendizagem e outras variáveis.

A partir destas considerações, Wiley (2000) optou pela utilização do átomo como metáfora, uma vez que este é um elemento muito pequeno que pode ser combinado e re combinado para criar moléculas. A constituição destas (unidades de aprendizagem) requer a seleção de átomos que apresentem características específicas. Esta metáfora para OA amplia a de uma peça de LEGO, pois considera que:

- Devido à estrutura interna de um átomo nem todos são combináveis entre si;
- Torna-se necessário algum nível de conhecimento prévio para a realização das combinações necessárias.

Já Paquette e Rosca (2002) consideram que uma metáfora orgânica poderia representar melhor um OA, pois além das características das metáforas apresentadas anteriormente, refletiria também a individualidade e a contextualização dos mesmos.

A partir desta diversidade de pontos de vista percebe-se que OAs podem ser caracterizados como uma coleção independente de elementos educacionais reutilizáveis e granulares que possibilitam um significado contextual sem, contudo, configurar um elemento que possa ser utilizado somente em um único contexto (ALDERMAN; BARRIT, 2004). O reuso dos OAs envolve a utilização de metadados (descriptor do recurso) para a classificação e armazenagem dos mesmos.

Neste sentido, uma análise sobre as definições de OAs permite verificar que o conceito de reusabilidade é similar ao de programação orientada a objetos utilizada no desenvolvimento de softwares. Ao invés de reescrever um código já elaborado anteriormente, o programador faz uma busca em uma biblioteca de códigos (metadados), seleciona e insere o código pré-escrito em seu programa. De modo análogo, o professor ao criar um curso, módulos, ou qualquer elemento de aprendizagem, pode pesquisar em uma biblioteca de OAs (repositório) e selecionar os mais adequados à proposta educacional (objetivos, metodologia, estilos de aprendizagem, grau de dificuldade, pré-requisitos, etc.).

A transposição do conceito de metadados para a esfera de OAs, conseqüentemente, pode ser interpretada como a catalogação de informações. E a sua estruturação e padronização resultam no Repositório de Objetos de Aprendizagem que é discutido no próximo capítulo. Neste sentido, o uso de metadados permite ao corpo docente, ou a quem o utilizar, a realização de buscas e consultas para a verificação da existência de OAs que atendam a necessidades específicas.

3 REPOSITÓRIOS DE OBJETOS DE APRENDIZAGEM

A crescente disponibilização de OAs na Web, e a facilidade de acesso implicam a necessidade de gerenciamento destes. Propostas neste sentido permitem otimizar a busca e seleção de materiais educativos, aumentar sua reusabilidade e potencializar o processo educacional.

Com este intuito, surgiram na Web, os Repositórios de Objetos de Aprendizagem (ROAs)¹, bases de dados que utilizam metadados para catalogar e avaliar os OAs. Deste modo, ROAs são bibliotecas digitais que armazenam OAs ou referências e suas propriedades de modo padronizado, facilitando a utilização dos mesmos.

Na Figura 3-1 é apresentado um exemplo de um ROA conhecido como MERLOT (*Multimedia Educational Resource for Learning and Online Teaching*) que possui mais de 16.000 OAs catalogados. Basicamente eles estão divididos em coleções (Humanas, Matemática, Ciência e Tecnologia, Ciências Sociais, etc.) e em sub-coleções. Em seus metadados constam algumas informações primárias do OA e uma avaliação realizada por membros da comunidade. A pesquisa deste ROA é realizada através de palavras-chaves pelos usuários.

¹ Em inglês os repositórios são denominados de *Learning Objects Repositories (LOR)*.

The screenshot displays the MERLOT website interface. At the top, the MERLOT logo is on the left, and a search bar is on the right. Below the logo, a navigation bar contains links: Home, Communities, Learning Materials, Member Directory, My Profile, and About Us. The main heading is 'Learning Materials', with a link to 'Become a Member | Log In'. Below this, the breadcrumb path is 'Browse Path: All > Mathematics and Statistics > Mathematics'. A 'Contribute A Material' button is also present.

The left sidebar shows 'Matching Categories' with links to various subjects like Functional Analysis, Neuron Function, and Mathematics. Under 'Mathematics', there are links to specific topics such as Algebra and Number Theory (90), General and Liberal Arts, Math (157), Geometry and Topology (109), Mathematical Modeling (46), Mathematics Publishing Tools (28), Numerical Analysis (26), Pre-Calculus Mathematics (196), Analysis (35), Applied Mathematics (10), Calculus (149), Developmental Mathematics (134), Differential Equations (43), Discrete Mathematics (71), Dynamical Systems (48), and Foundations of Mathematics (36). Below this is a 'Contribute a Material' section with fields for Title and URL, and a 'Next' button. A 'Recent searches' section shows the search term 'function'.

The main content area shows search results for 'function' in the 'Mathematics' category. It indicates 'Items 1-10 shown of 90 results' and 'Sort by: Overall Rating'. The results are listed in a table-like format with columns for item title, author, description, type, date added, and peer reviews/comments/assignments.

Item Title	Author	Description	Type	Date Added	Peer Reviews	Comments	Personal Collections	Assignments
Addition of Ordinates	Laura Shears	Flash program that tests students' graphical understanding of addition or subtraction of...	Drill and Practice	Mar 24, 2007	(not reviewed)	(none)	(none)	(none)
Key Radian Values on the Unit Circle	Laura Shears	This program provides practice thinking in terms of radian measure. Students can click on wedges of...	Drill and Practice	Mar 24, 2007	(not reviewed)	(none)	(none)	(none)
Taylor Polynomial Approximation Applet	Mike May	This applet is a sub-site of the Math Applets for Calculus at SLU site. This applet provides a...	Simulation	Apr 07, 2007	(not reviewed)	(none)	(none)	(none)
Functions Defined by Series	Mike May	This applet is a sub-site of the Math Applets for Calculus at SLU site. This applet is designed for the...	Simulation	Apr 08, 2007	(not reviewed)	(none)	(none)	(none)
Function Grapher	Steven R. Costenoble	Graphs one or more functions of a single variable, with zoom in/out and other nice features.	Simulation	Mai 31, 2001	Peer Review ★★★★★	Comments (3) avg: ★★★★★	Personal Collections (12)	Assignments (none)
G3d	Eugene Agichtein	Graphs functions in 3D - allows user to rotate the surfaces. slow and still a little buggy - mostly...	Simulation	Jan 29, 1998	Peer Review ★★★★★	Comments (2) avg: ★★★★★	Personal Collections (none)	Assignments (none)

Figura 3-1: Exemplo de Repositório de Objetos de Aprendizagem.
Fonte: <http://www.merlot.org>

Os ROAs podem ser analisados e categorizados através de características que norteiam seu estilo (MACLEOD, 2005; NEVEN; DUVAL, 2002):

- Padrões de Metadados;
- Abrangência;
- Quantidade de objetos;
- Direitos Autorais;
- Tecnologia;
- Avaliação;
- Domínio do conhecimento;
- Tipo de acesso.

Utilizando-se destas características e do mapeamento de ROAs disponíveis na Internet (Anexo A), foi definido um universo de OAs que integram este estudo.

Como pode ser observado (vide exemplo acima do MERLOT), a quantidade de OAs catalogados em repositórios é significativa em diferentes áreas de conhecimento. No entanto, uma questão que vem sendo investigada (ARAÚJO; FERREIRA, 2004) e que constitui um desafio para instituir efetivamente sua reusabilidade é a falta de interação entre vários ROAs, pois diversos métodos de qualificação e padrões de armazenagem (*IEEE-LOM*, *DublinCore*, *IMS Learning Design*, *ARIADNE*, etc.) foram criados.

A seguir, serão apresentados detalhadamente os itens que integram a análise dos ROAs.

3.1 PADRÕES DE METADADOS

As propriedades dos objetos são armazenadas em metadados definidos pela organização desenvolvedora do ROA ou por organizações de padronizações. Os metadados comumente encontrados são aderentes ou variantes do LOM (*Learning Object Metadata*), DCMI (*DublinCore Metadata Initiative*) ou SCORM (*Sharable Content Object Reference Model*).

3.1.1 LOM

O LOM (*Learning Object Metadata*) é um esquema de metadados conceitual para objetos de aprendizagem definido pelo *IEEE Learning Technology Standards Committee* (IEEE-LTSC)². Este padrão possui um modelo hierárquico que descreve as características relevantes do objeto em que ele se aplica, constituindo uma estrutura de árvore de 67 elementos (LTSC, 2002).

² O IEEE-LTSC objetiva o desenvolvimento de padrões técnicos, métodos de desenvolvimento de software para manutenção e interoperabilidade de sistemas computacionais voltados à educação/treinamento, práticas recomendadas, etc.

Este esquema permite uma diversidade lingüística tanto do ponto de vista do objeto de aprendizagem como do metadado que o descreve. No entanto, este padrão não define como utilizá-lo em um sistema tecnológico. Neste sentido, sua principal função é facilitar a pesquisa, avaliação, aquisição e o uso de objetos de aprendizagem por aprendizes, instrutores ou processos automatizados de softwares. O LOM também objetiva facilitar o compartilhamento e a troca de objetos de aprendizagem, permitindo o desenvolvimento de unidades de aprendizagem (através de encadeamento e/ou combinação de OAs), de catálogos e de inventários.

Na estrutura de árvore do LOM, os recursos podem ser classificados em nove categorias, cada uma oferecendo uma visão distinta de um recurso (LTSC, 2002; ARAÚJO; FERREIRA, 2004):

- Geral (*General*): reúne informações de ordem geral para a descrição do OA;
- Ciclo de Vida (*Lifecycle*): condensa elementos pertinentes ao histórico e ao desenvolvimento do OA, assim como o estado atual deste;
- Meta-metadado (*Meta-metadata*): agrupa informações referentes ao metadado do OA e não do OA em si;
- Técnica (*Technical*): aborda as características e os requisitos técnicos para a utilização do OA;
- Educacional (*Educational*): reúne informações vinculadas às características pedagógicas e educacionais do OA;
- Direitos (*Rights*): apresenta informações relacionadas aos direitos de propriedade intelectual e condições para a utilização do OA;
- Relação (*Relation*): permite a inclusão de características pertinentes ao vínculo do OA com outros objetos;
- Anotação (*Annotation*): área para comentários e informações em relação à utilização educacional do OA;
- Classificação (*Classification*): possibilita classificar o OA de acordo com um sistema classificatório específico.

Contudo, é relevante destacar que a norma IEEE 1484.12.1 (IEEE-LTSC, 2004) indica que não é necessário que o LOM contenha todos os atributos.

3.1.2 DublinCore

O *DublinCore Metadata Initiative* (DCMI) é uma organização internacional voltada à expansão da adoção de metadados padronizados e ao desenvolvimento de vocabulários para descrição de recursos que permitam a criação de um sistema eficaz de busca de informação, colaborando para que a mesma retorne resultados bem específicos, minimizando conseqüentemente o tempo de pesquisa. Desta forma, o DCMI provê um padrão internacional simples e extensível de metadados para contribuir na descrição de recursos, possibilitando que estes sejam adaptados de acordo com requisitos adicionais (DCMI, 2007).

Neste contexto, a pesquisa e o desenvolvimento deste padrão (DCMI, 2007) objetivam torná-lo:

- *Simples*, permitindo que pessoas que não sejam especialistas possam facilmente criar registros descritivos, provendo uma recuperação efetiva deste recurso na rede;
- *Comumente entendível*, provendo ao usuário achar seu caminho através do suporte de um conjunto de elementos comuns, os quais semanticamente são entendidos e suportados universalmente;
- *Com escopo internacional*, colaborando desta forma para a sua difusão. Sua versão original foi desenvolvida em Inglês, mas outras versões foram criadas em outras línguas, como Norueguês, Japonês, Francês, Português, Alemão, Grego, Espanhol, entre outras;
- *Extensível*, possibilitando que outros grupos especialistas em metadados possam criar, adicionar e administrar elementos especializados nas necessidades de cada comunidade.

Seu foco é definir metadados que possam descrever qualquer tipo de documento, páginas web, vídeos e outros tipos de mídias em benefício da troca de informações. Neste sentido, este padrão não foi criado com a mesma perspectiva do LOM, que trata de metadados somente para OAs. Todavia, o seu núcleo, conhecido como *DublinCore Element Set*, foi definido a partir de um denominador comum entre vários padrões de metadados que resultaram em 15 elementos genéricos, opcionais e repetíveis, formando um grupo também conhecido como “Simples”. Este grupo possui os seguintes elementos (DCMI, 2007):

- Título (*Title*);
- Autor (*Creator*);
- Assunto (*Subject*);
- Descrição (*Description*);
- Editor (*Publisher*);
- Contribuidor (*Contributor*);
- Data (*Date*);
- Tipo (*Type*);
- Formato (*Format*);
- Identificador (*Identifier*);
- Origem (*Source*);
- Linguagem (*Language*);
- Relacionamento (*Relation*);
- Cobertura (*Coverage*);
- Direitos (*Rights*).

Existe ainda outro grupo denominado *Qualificado* que é formado por mais três elementos (DCMI, 2007): Audiência, Procedência e Proprietário do Direito. E por fim, um grupo que refina a semântica dos elementos, de tal modo, que eles possam otimizar o processo de busca do recurso.

3.1.3 SCORM

O *Sharable Content Object Reference Model* (SCORM) surgiu em 1997 (ADL, 2006) como uma iniciativa do governo Americano através da *Advanced Distributed Learning Initiative* (ADL), instituída pelo *Department of Defense* (DoD), e da *White House Office of Science and Technology Policy* (OSTP). A ADL tinha como objetivo prover acesso a um material de ensino em qualquer lugar e a qualquer hora, que poderia ser customizado conforme necessidades individuais.

Para atingir estes objetivos, de forma a promover a criação de conteúdos de aprendizagem reusáveis como objetos instrucionais, a ADL estruturou o SCORM. Este, por sua vez, é baseado em computação e aprendido através da Web e pauta-se na reusabilidade, acessibilidade, interoperabilidade e durabilidade tendo em vista a proposta de um padrão que propicie a independência de plataforma e facilidade de migração de cursos para diferentes sistemas de gerenciamento de aprendizagem (*Learning Management Systems – LMS*).

O SCORM descreve uma estrutura através da harmonização de um conjunto de guias, especificações e padrões de diversas entidades (*Aviation Industry CBT Committee – AICC*, *IMS* e *IEEE*). Estes materiais técnicos são agrupados em três grandes tópicos (ADL, 2006):

- *Modelo para Agregação de Conteúdo (Content Aggregation Model – CAM)*: apresenta métodos consistentes para rotulação, empacotamento, armazenamento, troca e pesquisa de OAs;
- *Ambiente de Tempo de Execução (Run-Time Environment – RTE)*: trata dos requisitos necessários para assegurar a interoperabilidade do conteúdo entre diferentes LMS;
- *Navegação e Seqüência (Sequencing and Navigation – SN)*: descreve um método para representar o comportamento pretendido em uma experiência de aprendizado em atividades seqüenciais consistentes.

Para o sucesso deste modelo, três critérios básicos são apontados como necessários pela ADL (2006):

- A necessidade de ser compreensível e implementado pelos desenvolvedores de conteúdo de aprendizagem;
- A adoção e compreensão pelo maior número de pessoas;
- A apresentação da possibilidade de mapeamento a partir de um modelo específico para o projeto de um sistema educacional.

No entanto para estimular o seu uso como um modelo, o SCORM adaptou estes critérios em uma lista com requerimentos funcionais para todo ambiente de ensino baseado no SCORM³.

- Acessibilidade: habilidade para localizar e acessar um OA remotamente;
- Adaptabilidade: habilidade para customizar OAs de acordo com a necessidade;
- Disponibilidade: habilidade para aumentar eficiência e produtividade e diminuir os custos e o tempo envolvido na disponibilização do OA;
- Durabilidade: habilidade para acompanhar o desenvolvimento e mudanças da tecnologia sem custo para reelaboração, reconfiguração, etc.;
- Interoperabilidade: habilidade para apresentar compatibilidade entre ambientes educacionais diferentes;
- Reusabilidade: flexibilidade necessária para incorporar OAs em múltiplas aplicações e contextos.

Paralelamente a estes requerimentos vinculados aos padrões, outra característica relevante é o conceito de aprendizado através da Web, que permite maximizar o acesso e o reuso de OAs através de praticamente qualquer tipo de mídia.

³ Em inglês, estes requerimentos são conhecidos como ADL's "ilities", pela ortografia dos adjetivos.

3.2 ABRANGÊNCIA

Esta característica denota o nível de abrangência do ROA, ou seja, qual a disponibilidade deste repositório quanto à localidade e à possibilidade de acesso. Desta forma, podem ser percebidos quatro grupos:

- **Interno e Restrito:** repositórios com disponibilidade de acesso restrito a alguns usuários da *Intranet* de uma organização;
- **Interno e Aberto:** repositórios com disponibilidade de acesso livre a todos os usuários da *Intranet* de uma organização;
- **Externo e Restrito:** repositórios com acesso (via Internet) controlado e limitado a alguns usuários;
- **Externo e Aberto:** repositórios com acesso livre (via Internet) a todos os usuários.

3.3 DIREITOS AUTORAIS

Na constituição de repositórios, outro fator a ser considerado são os Direitos Autorais (*Copyright*), ou seja, o direito que o autor tem de controlar o uso que se faz dos OAs. As formas encontradas nos ROAs pesquisados (Anexo A) foram:

- **Objetos de Aprendizagem fechados:** a sua utilização *on-line* ou *off-line* é feita através de pagamento;
- **Objetos de Aprendizagem semi-abertos:** a sua utilização *on-line* é livre, no entanto para que se faça a transferência do arquivo é necessário o pagamento;
- **Objetos de Aprendizagem abertos:** a sua utilização *on-line* e/ou *off-line* é livre.

3.4 AVALIAÇÃO

Esta característica enumera o tipo de avaliação que é utilizado nos ROAs pesquisados (Anexo A). Foram identificados três tipos de avaliações:

- **Revisão por pares (*Peer review*):** a avaliação é feita por usuários do ROA;
- **Lista de Verificação (*Checklists*):** a avaliação é feita utilizando-se uma lista de parâmetros a serem analisados com respectivos pesos;
- **Sem avaliação:** repositórios que não disponibilizam nenhum tipo de apreciação em relação aos OAs armazenados.

3.5 DOMÍNIO DO CONHECIMENTO

Esta característica indica a área de conhecimento do repositório, sendo possível encontrar:

- Repositórios de áreas específicas: limitando a sua abrangência em determinada área de conhecimento;
- Repositórios generalistas: OAs abrangendo várias áreas do conhecimento.

A partir deste escopo, é possível direcionar o pesquisador de OAs para o ROA que apresente os recursos mais adequados à área de interesse.

Tendo em vista os elementos expostos neste capítulo, é possível tecer algumas considerações. A proposta atual de SCORM e de DublinCore são direcionadas ao conteúdo (organização e seqüência), à sua forma de apresentação e ao acompanhamento das ações do estudante em relação à interação com o material. Contudo, estes padrões não apresentam elementos que possibilitem a especificação de uso contextual que não em situações exclusivas entre estudante e OA. Neste sentido faltam informações no metadado que apresentem subsídios ao professor para que este tenha uma visão contextual do uso do OA.

Essas propostas também não contém informações sobre abordagens pedagógicas como a da aprendizagem baseada em problemas (*Problem-Based Learning*) (BARROWS; TAMBLYN, 1980), aprendizagem baseada em projetos (*Project-Based Learning*) (BLUMENFELD et al., 1991) e aprendizagem colaborativa (*Computer Supported Collaborative Learning - CSCL*) (Lejeune, 2003).

Com base nas observações acima, pode-se dizer que, dos padrões analisados neste capítulo, o que melhor se adapta à proposta deste trabalho é o IEEE-LOM.

4 PARÂMETROS PARA CLUSTERIZAÇÃO DE OBJETOS DE APRENDIZAGEM

A discussão relacionada à qualificação de OAs e o estabelecimento de uma metodologia para o processo avaliativo de OAs envolve os seguintes elementos:

- Ponto de vista da avaliação (Avaliador);
- Elemento avaliado;
- Metodologia de avaliação;
- Objetivo da avaliação;
- Utilizadores dos resultados da avaliação.

Percebe-se, com isso, que o processo de avaliação de um objeto de aprendizagem pode considerar óticas distintas: grupo de usuários, grupo de desenvolvedores, grupo de alunos, grupo de professores, entre outros (WILLIAMS, 2000). Dentre as óticas existentes, neste trabalho será destacado o ponto de vista do avaliador.

À primeira vista, o papel de avaliador deve ser realizado por um grupo de alunos ou de professores. A motivação do grupo de alunos em avaliar os objetos se dá por conta deles serem os usuários diretos dos OAs e perceberem a efetividade destes no processo de ensino.

O grupo de professores tem a motivação de serem os usuários primários dos OAs, pois eles desenvolvem seus próprios métodos educacionais e criam objetos de todos os tipos para atender às necessidades de aprendizado. Entretanto, nem sempre, estes grupos consideram critérios que permitam refletir sobre a qualidade e efetividade do material elaborado.

Outro ponto a ser considerado na avaliação de OAs é a definição clara do que está sendo avaliado. No entanto, pela falta de consenso sobre o conceito de OAs, são enumerados critérios (apresentados no item 4.1 e 4.2) que definam índices de qualidade educacional do objeto avaliado. Portanto, foi avaliada a função do OA, em torno do qual existe certo consenso, que é a de facilitar o processo de aprendizagem, potencializando este processo.

A contextualização do OA através de características que denotem a similaridade existente entre os mesmos deve também colaborar na enumeração de elementos para a avaliação utilizada na rede neural artificial elaborada.

Conforme Silva e Mustaro (2006), uma metodologia para a definição destes elementos pauta-se em dois grupos:

- **Características Intrínsecas aos Objetos de Aprendizagem:** são avaliadas as qualidades intrínsecas, que são as qualidades inerentes do objeto de aprendizagem, mostrando desta forma a potencialidade do objeto (Tabela 4-1 – apresentada no item 4.1);
- **Valor Educacional do Objeto de Aprendizagem:** é avaliado o potencial valor educacional do objeto de aprendizagem sem considerar os valores inerentes do mesmo (Tabela 4-2 – apresentada no item 4.2).

Estas informações deveriam estar armazenadas em metadados nos repositórios de objetos de aprendizagem. No entanto, informações avaliativas não estão freqüentemente disponíveis em padrões o que implica a necessidade de desenvolvimento e teste de critérios avaliativos com base em um conjunto pré-definido.

Por isso, este trabalho propôs a avaliação dos objetos de aprendizagem a partir de uma lista de verificação que pondera elementos-chave através de pesos e notas, sendo necessária a atribuição de notas a cada item, permitindo, desta forma que ferramentas inteligentes trabalhem com estas informações, colaborando na reusabilidade dos OAs.

A configuração proposta para a avaliação, adaptada de Silva e Mustaro (2006), é apresentada a seguir de maneira estruturada e detalhada.

4.1 CARACTERÍSTICAS INTRÍNSECAS AOS OBJETOS DE APRENDIZAGEM

A avaliação deste conceito envolve os parâmetros abaixo (Tabela 4-1), discutidos no capítulo 3:

- O peso varia de um a três de acordo com o grau de importância do critério avaliado.
- As notas variam em uma escala de 0-10, sendo 0, quando o critério não é atendido pelo objeto de aprendizagem e 10 quando o critério é atendido plenamente;
- Para os critérios que englobam sub-critérios, as notas são obtidas através do resultado da média ponderada destes.

Tabela 4-1: Parâmetros de Avaliação Intrínseca para Objetos de Aprendizagem.

Item	Critério	Descrição do Critério	Peso	Nota
A	Reusabilidade	Nível de reusabilidade do OA em contextos diferentes.	2	<ul style="list-style-type: none"> ▪ Altamente Reusável: 10 ▪ Reusável: 8-9 ▪ Pouco Reusável: 6-7 ▪ Potencialmente Reusável: 4-5 ▪ Não Reusável: 0-3
B	Granularidade	Nível de granularidade do OA.	1	<ul style="list-style-type: none"> ▪ Um conceito específico: 6-10 ▪ Vários conceitos: 0-5
C	Qualidade do Metadado	Avaliação dos itens que constituem o metadados.	3	<p>[A nota é obtida mediante a média ponderada dos sub-critérios.]</p> $\frac{\sum P_{C,i} \times N_{C,i}}{\sum P_{C,i}}$
C.1	Objetivos	Descrição dos objetivos.	3	Escala de 0-10
C.2	Palavras-chave	Unitermos relacionados ao OA.	2	Escala de 0-10
C.3	Assunto	Descrição das áreas de conhecimento que possam utilizar o OA.	1	Escala de 0-10
C.4	Pré-requisitos	Descrição das competências e/ou habilidade necessárias para compreensão e uso do OA.	3	Escala de 0-10
C.5	Copyright	Apresentação do detentor dos direitos autorais do OA.	1	Escala de 0-10
C.6	Descrição	Exposição das características, funções e estrutura do OA.	2	Escala de 0-10
D	Plug-in	Softwares adicionais instalados no micro. A nota será inversamente proporcional à quantidade de softwares necessários para a utilização.	1	Escala de 0-10
E	Exatidão no assunto	Conteúdo do objeto de aprendizagem está atualizado com o assunto proposto.	3	Escala de 0-10

Sendo:

- P : Peso do critério.
- N : Nota do critério.
- $C.i$: Índices dos critérios dos sub-itens do item C.

A nota deste grupo de critérios é obtida mediante o resultado da equação:

$$CritériosA = \frac{\sum P_i \times N_i}{\sum P_i} \quad (4-1)$$

Sendo:

- P : Peso do critério;
- N : Nota do critério;
- I : Índice do critério, variando de “A” até “E”.

O resultado máximo para $CritériosA$ é de 10 pontos.

4.2 VALOR EDUCACIONAL DO OBJETO DE APRENDIZAGEM

A complementação da avaliação intrínseca é feita com base nos parâmetros apresentados na Tabela 4.2. A proposta de escala, de pesos e de representação numérica pertinente aos critérios vinculados ao valor educacional do OA seguem a mesma estrutura apresentada no item 4.1.

Tabela 4-2: Parâmetros de Avaliação Extrínseca para Objetos de Aprendizagem.

Item	Critério	Descrição do Critério	Peso	Nota
F	Grau de Interatividade	Nível de interatividade de acordo com os sub-critérios discriminados abaixo.		
F.1	Linear	Interatividade sequencial, pré-estabelecida e sem resposta pautada na ação do usuário.	1	0 ou 10
F.2	Hierárquico	Sequência estabelecida através de níveis para acesso às informações.	1	0 ou 10
F.3	Objeto	Ação específica determinada por objetos ou botões.	1	0 ou 10
F.4	Suporte	Sistema de ajuda contextual.	1	0 ou 10
F.5	Atualização	Manipulação de problemas vinculados a um desempenho específico com resposta relacionada à interação.	1	0 ou 10
F.6	Construção	Manipulação de objetos para atingir objetivos propostos.	1	0 ou 10
F.7	Simulação	Manipulação de sistemas complexos com resposta diferenciada.	1	0 ou 10
F.8	Hipertextual	Navegação por meio de vínculos de hipertexto.	1	0 ou 10
G	Formas de Uso	Possibilidades de utilização de acordo com os sub-critérios abaixo.		
G.1	Orientada	Nível de qualidade da utilização do OA perante a orientação do professor.		0 ou 10
G.2	Autônoma	Nível de qualidade da utilização do OA sem monitoramento.		0 ou 10
H	Usabilidade		2	[A nota é obtida mediante a média ponderada dos sub-critérios.] $\frac{\sum P_{H,i} \times N_{H,i}}{\sum P_{H,i}}$
H.1	Orientação ao Usuário	Disponibilização de informações e dicas para uso do OA.	3	Escala de 0-10
H.2	Interface Amigável	Facilidade de utilização da interface do OA.	2	Escala de 0-10

Sendo:

- P : Peso do critério;
- N : Nota do critério;
- $H.i$: Índices dos critérios dos sub-itens do item H.

Após a qualificação do material, através dos métodos descritos anteriormente, faz-se necessário disponibilizar estas informações de forma que as mesmas possam ser pesquisadas e selecionadas rapidamente, minimizando o tempo necessário para a criação de materiais de aprendizagem com potencial eficácia em um contexto específico.

Processos educacionais podem se tornar mais significativos e interativos se forem considerados elementos pertinentes à mídia digital e aos sistemas de hipertexto, sobretudo em relação à interatividade. Na literatura geralmente se encontra uma arquitetura pautada em quatro tipos de interatividade: estudante-

interface, estudante-conteúdo, estudante-professor e estudante-estudante. Contudo, como os objetos de aprendizagem são elementos diferenciados e podem ser inseridos em um LMS ou usados isoladamente é necessário atentar para outras características que possam ser adaptadas a este e possibilitem a análise dos graus de interatividade existentes.

Neste sentido, uma proposta que amplia esta estrutura e oferece subsídios para uma análise mais adequada de OAs é a classificação de graus de interatividade apresentada por Robert Sims (1995). Esta pauta-se numa perspectiva de desenvolvimento de aplicações educacionais em multimídia que, por não ser mutuamente excludente, permite diversas combinações de acordo com o contexto educacional. De maneira complementar, este esquema de interatividade também é caracterizado pela combinação de metodologias didáticas para o engajamento e motivação dos estudantes em ambientes digitais. A seguir são descritos os aspectos e escopo pertinente à classificação de interatividade proposta por Sims.

O primeiro elemento proposto é a *interatividade linear*. Esta é caracterizada pela apresentação de conteúdo de forma seqüencial.

Já a *interatividade hierárquica* difere da interatividade linear por apresentar dois níveis. O primeiro é composto de um menu estruturado com opções pré-definidas. Após a seleção de um item a estrutura torna-se linear.

A terceira espécie de interatividade é a *interatividade de objeto*. Nesta a ativação de botões ou objetos resulta na apresentação de algum tipo de resposta.

O quarto tipo de interatividade é denominado de *interatividade de suporte*. Esta é caracterizada pela apresentação de sistemas de ajuda contextual ou pela disponibilização de tutoriais complexos.

A quinta categoria de interatividade é a *interatividade de atualização*. Esta envolve a disponibilização de problemas e a apresentação de resposta conforme a solução apresentada pelo estudante.

A sexta categoria de interatividade é a *interatividade de construção*. Esta envolve a manipulação de objetos para atingir um determinado objetivo educacional ou para obter acesso a um conteúdo de nível hierárquico superior.

A sétima forma de interatividade é denominada de *interatividade de simulação*. Esta é caracterizada pela apresentação de simulações que comportam diferentes respostas de acordo com as escolhas/definições dos estudantes.

A oitava forma de interatividade é a *interatividade por vínculo de hipertexto*. Esta apresenta uma estrutura de navegação por vínculos hipertextuais em ambientes onde existe uma quantidade de informação que possa sobrecarregar o usuário e prejudicar o processo de aprendizagem.

Estas categorias complementam os tipos de interação comumente avaliados e possibilitam diversas combinações em objetos de aprendizagem de acordo com as propostas educacionais e dinâmicas dos cursos.

De forma complementar, também é necessário atentar para questões vinculadas à interação humano-computador e mais especificamente à usabilidade de interfaces digitais relacionadas aos processos de aprendizagem mediada pela utilização de OAs. O termo usabilidade, conforme a definição presente na ISO 9241-11 (1998), relaciona-se à capacidade de utilização de um produto em relação às especificidades de público, objetivos e contexto, de forma a possibilitar que esta experiência seja eficiente e satisfatória.

De acordo com Nielsen (1993), a questão da navegação simples e de apreensão direta envolve diversos elementos, dentre os quais se destacam, devido ao escopo da pesquisa, a facilidade de aprendizagem e de memorização, a eficiência de uso e a baixa taxa de erros. A partir disso, pode-se dizer que o uso de um determinado OA pode não ser satisfatória se este apresentar problemas de usabilidade. Dentre estes, tendo em vista a proposta desta pesquisa, pode-se destacar a orientação ao usuário e a capacidade da interface ser amigável no sentido de apresentar elementos que possibilitem uma navegação simples e intuitiva.

O primeiro elemento refere-se tanto à organização das informações como à apresentação gráfica (localização, agrupamento, estrutura, etc.) dos OAs. De forma complementar, o segundo princípio envolve a utilização propriamente dita do OA, o que pode inviabilizar uma determinada atividade educativa e constituir um obstáculo que exige tentativa e erro e desvia o foco educacional, ocasionando uma sobrecarga cognitiva (WURMAN, 1995; SOUZA, 2004).

A proposta de combinação dos elementos intrínsecos e extrínsecos constitui uma arquitetura simplificada que mantém os elementos mais relevantes do IEEE-LOM e, devido à flexibilidade deste, apresenta alguns itens complementares que podem contribuir para seleção de OAs em situações de aprendizagem presenciais, a distância ou híbridas.

Uma vez que foram apresentadas as definições de OAs e ROAs, alguns padrões relevantes de metadados e as características avaliativas que foram utilizadas neste trabalho, o próximo capítulo discute elementos pertinentes a Redes Neurais Artificiais, especialmente a Rede de Kohonen, para em seguida abordar a implementação dos OAs com a Rede de Kohonen.

5 ELEMENTOS DE REDES NEURAIS

A Inteligência Artificial (IA) é uma ciência recente (RUSSEL; NORVIG, 2004), tendo surgido em um seminário no verão de 1956 no *Dartmouth College* na cidade de *Hanover* em *New Hampshire*. Talvez o resultado mais duradouro deste seminário tenha sido o próprio nome “Inteligência Artificial”, sugerido por John McCarthy para esta ciência.

Segundo a *American Association for Artificial Intelligence* (AAAI, 2006), Inteligência Artificial pode ser caracterizada como a compreensão científica dos mecanismos relacionados ao pensamento e ao comportamento inteligente e a transferência destes mecanismos para máquinas. Rich e Knight (1994) definem IA como a área da ciência da computação orientada ao entendimento, construção e validação de sistemas inteligentes, isto é, que exibem, de alguma forma, características associadas ao que denomina-se inteligência.

Desta forma, Inteligência Artificial é um ramo da Ciência da Computação que reúne inúmeras disciplinas normalmente associadas à inteligência humana, abrangendo desde estudos epistemológicos e filosóficos até robótica e sistemas adaptativos, incluindo modelos de redes neurais artificiais, algoritmos genéticos e sistemas especialistas, entre outros.

Após uma breve introdução sobre IA, este capítulo aborda o tópico específico de Rede Neural Artificial, apresentando suas similaridades com a Rede Neural Humana, os métodos de aprendizado envolvidos na criação deste tipo de rede e a conceitualização matemática. Em seguida são apresentados, detalhadamente, os mapas auto-organizáveis (Rede de Kohonen), juntamente com seus algoritmos, funções e parâmetros de otimização, utilizando-se para tanto autores como Kohonen (2001), Haikyn (2001), Kasabov (1998), McCulloch e Pitts (1943).

5.1 REDE NEURAL ARTIFICIAL

É um dos campos da Inteligência Artificial que tem como motivação o reconhecimento de que o cérebro humano processa informações de uma forma inteiramente diferente do computador digital convencional (HAYKIN, 2001). Isto implica a utilização de um sistema de processamento paralelo, distribuído e não-algorítmico, que, em algum nível, relembra a estrutura do cérebro humano.

Este sistema tem como função primária armazenar conhecimento experimental e torná-lo disponível para uso. De maneira complementar, ele se assemelha ao cérebro em dois aspectos (HAYKIN, 2001):

- O conhecimento é adquirido através de um processo de aprendizado;
- Os pesos sinápticos são utilizados para armazenar o conhecimento adquirido.

Em razão da semelhança entre o cérebro humano e o funcionamento desta rede, e para proporcionar um melhor entendimento da mesma, é necessário primeiramente observar alguns aspectos biológicos das estruturas constituintes deste órgão: os neurônios. A Figura 5-1 apresenta as três seções do neurônio: corpo celular, dendritos e axônio.




Figura 5-1: Estrutura das seções do neurônio.

Os dendritos constituem a zona receptiva, e tem a função de receber as informações ou impulsos nervosos, oriundos de outros neurônios, e conduzi-las até o corpo celular, onde as informações são processadas e novos impulsos são gerados. Estes são encaminhados para outros neurônios através das linhas de transmissão, formadas pelos axônios. O ponto de contato entre a terminação de um axônio e o dendrito de outro neurônio é conhecido como sinapse. É através da sinapse que os neurônios se unem funcionalmente, formando redes neurais. Esta conexão através de sinapse pode impor ao neurônio receptivo excitação ou inibição, mas não ambas (HAYKIN, 2001; BRAGA; CARVALHO; LUDERMIR, 2000).

O corpo celular, por sua vez, combina os sinais recebidos, e, se o valor resultante for acima do limiar de excitação do neurônio, a célula emite um impulso que é transmitido para as células seguintes. Estima-se que haja aproximadamente 10^{11} neurônios no cérebro humano, totalizando um valor em torno de 10^{15} conexões ou sinapses (KASABOV, 1998).

De forma análoga, as redes neurais artificiais são compostas de nós ou neurônios. Estes são formados a partir de modelos matemáticos que se assemelham comportamentalmente aos neurônios biológicos.

A capacidade de aprendizado destes modelos matemáticos requer um conjunto reduzido de exemplos para posterior produção de respostas coerentes para dados não-conhecidos; ou seja, as redes neurais artificiais são capazes de extrair informações não apresentadas de forma explícita através de exemplos. Desta forma, encontram-se aplicações em várias áreas do conhecimento, dentre as quais podem ser destacadas as apresentadas abaixo (RUSSEL; NORVIG, 2004):

- Administração de projetos de investimentos;
- Análise de risco;
- Concessão de crédito;
- Diagnósticos mecânicos;
- Diagnósticos médicos;
- Previsões de comportamento para diversas finalidades (militares, *commodities*, ações, moedas, etc.);
- Clusterização.

O modelo anteriormente apresentado, considerando-se o número de camadas e os tipos de conexões, pode dar origem a redes neurais artificiais com diferentes arquiteturas: rede de camada única, rede de camadas múltiplas, rede cíclica e rede acíclica, as quais são detalhadas a seguir.

Quanto ao número de camada, pode-se ter: redes de camada única e redes de camadas múltiplas (RUSSEL; NORVIG, 2004). No primeiro caso, só existe um neurônio entre uma entrada qualquer e as saídas de rede (Figura 5-2).




Figura 5-2: Rede Acíclica de Camada Única.

Por outro lado, nas redes de camadas múltiplas, existe mais de um neurônio entre uma entrada qualquer e as saídas da rede (Figura 5-3).




Figura 5-3: Rede Acíclica de Camadas Múltiplas.

De forma complementar, as conexões podem ser caracterizadas como: acíclicas (ou diretas) e cíclicas (ou recorrentes) (RUSSEL; NORVIG, 2004). Nas redes acíclicas (Figura 5-2 e Figura 5-3), a alimentação dos neurônios ocorre em um único sentido, ou seja, a saída de um neurônio na *i*-ésima

camada da rede não pode ser usada como entrada de neurônios em camadas de índice menor ou igual a i (BRAGA; CARVALHO; LUDERMIR, 2000). Como exemplos deste tipo de rede, podem-se citar: *perceptron* de camada única, *perceptron* de camadas múltiplas e redes de função de base radial.

Para as redes cíclicas (Figura 5-4), o sinal de saída de um neurônio serve de alimentação para ele próprio, ou para outro neurônio localizado na mesma camada ou em alguma camada anterior, ou seja, a saída de algum neurônio na i -ésima camada da rede é usada como entrada do neurônio em camadas de índice menor ou igual a i (BRAGA, CARVALHO, LUDERMIR, 2000). Como exemplos, podem-se citar: redes competitivas, mapas auto-organizáveis de Kohonen, redes de Hopfield e modelos ART.

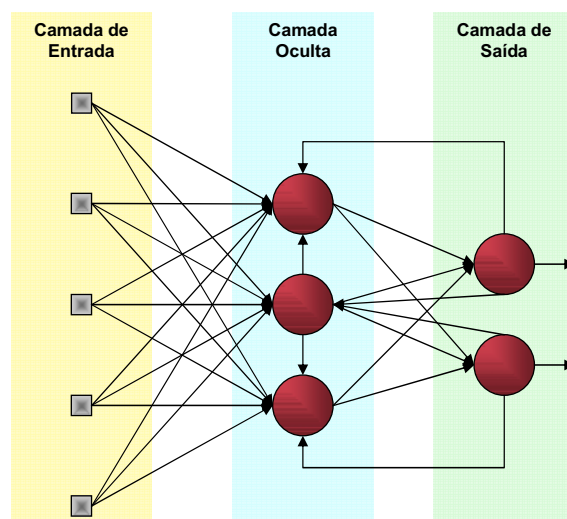


Figura 5-4: Rede Cíclica de Camadas Múltiplas.

Contudo, a modelagem da rede neural também pode ser influenciada pelo processo de aprendizado, que configura dois grupos distintos, os quais são detalhados nos próximos itens.

5.1.1 Métodos de Aprendizado

Em redes neurais pode-se dizer que a aprendizagem ocorre a partir do ambiente e visa a melhoria do desempenho (HAYKIN, 2001) a partir da utilização de exemplos e realização de interpolações e extrapolações (BRAGA; CARVALHO; LUDERMIR, 2000).

Este processo de aprendizagem ocorre através de ajustes aplicados aos pesos sinápticos (HAYKIN, 2001), que guardam, ao final do processo, o conhecimento que a rede adquiriu no ambiente que está operando. Um conjunto de procedimentos bem-definidos para adaptar estes parâmetros em uma Rede Neural Artificial (RNA), para que a mesma possa aprender uma determinada função, é chamada de algoritmo de aprendizado (BRAGA; CARVALHO; LUDERMIR, 2000). Este objetiva aprimorar a rede colaborando para que ela produza um resultado melhor e se torne mais instruída após cada iteração.

Como existem várias definições para aprendizagem, dependendo da área utilizada, alguns escritores na área de redes neurais (HAYKIN, 2001; BRAGA; CARVALHO; LUDERMIR, 2000), têm usado Mendel e McClaren (1970), que definem aprendizagem, como um processo pelo qual os parâmetros de uma RNA são adaptados através de um método de estimulação. O tipo de aprendizagem é determinado pela maneira que as modificações ocorrem.

Desta maneira, a estimulação e as modificações das redes ocorrem através do ambiente no qual a rede está inserida e pelo método que a modificação ocorre. Estes métodos, conhecidos como algoritmos de aprendizado, estão agrupados em dois grupos: aprendizado supervisionado e aprendizado não supervisionado.

O método de aprendizado supervisionado utiliza um supervisor (professor) que, dada uma determinada entrada, estabelece a resposta desejada. O objetivo deste treinamento é ajustar os parâmetros da rede de tal forma que o par entrada e saída estejam corretos.

Este processo de aprendizado inicia-se com o ambiente informando um vetor de entrada, que após o devido processamento, gera uma saída. Esta é comparada com o resultado desejado pelo professor, que já tem um conhecimento prévio deste ambiente, identificando-se o erro. Em seguida, os parâmetros são ajustados combinando-se o erro e o vetor de entrada. O processo repete-se com outros vetores de entrada até que o conhecimento do ambiente disponível ao professor é adquirido pela rede neural. Neste momento, a fase de aprendizagem está terminada e a rede neural tem condições de

operar de maneira autônoma (adaptado de HAYKIN, 2001). Na Figura 5-5, encontra-se um diagrama apresentando o processo descrito anteriormente.

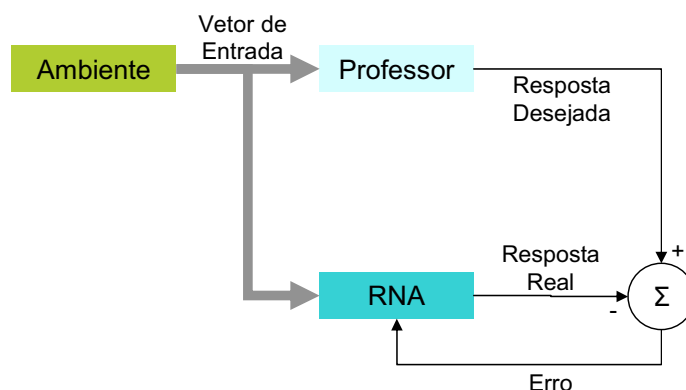


Figura 5-5: Diagramas de blocos de aprendizagem supervisionada.
(HAYKIN, 2001)

Além do conceito de aprendizado, existem diferentes métodos que são usados com o objetivo de minimizar o erro e otimizar o algoritmo, como por exemplo: correção de erros, regra delta e retropropagação (*backpropagation*).

No método de aprendizado não supervisionado, não há um supervisor (professor) para informar o par entrada e saída de forma correta (Figura 5-6). Em vez disso são dadas condições para a medição da representação que a rede deve aprender, e os parâmetros livres da rede são otimizados em relação a esta medida. Uma vez que a rede tenha se ajustado às regularidades estatísticas dos dados de entrada, ela desenvolve a habilidade de formar representações internas para codificar as características da entrada e, desse modo, criar automaticamente novas classes (HAYKIN, 2001).



Figura 5-6: Diagrama de blocos de aprendizagem não-supervisionada.
(HAYKIN, 2001)

Um dos métodos para este tipo de aprendizagem é a aprendizagem competitiva que se baseia na idéia de que dado um padrão de entrada, as unidades de saída disputem entre si para serem ativadas (BRAGA; CARVALHO; LUDERMIR, 2000). Como exemplo, em sua forma mais simples, pode-se citar uma rede neural de duas camadas: uma camada de entrada e

uma camada competitiva, sendo a primeira totalmente conectada à segunda e esta, por sua vez, com conexões de realimentações.

Nesta rede, de acordo com as entradas fornecidas, existe uma competição entre os neurônios, respeitando uma regra de aprendizagem, para que sejam ativados, inibindo os demais, de tal forma que somente um neurônio de saída esteja ativo (HAYKIN, 2001). Este neurônio vencedor é conhecido como “neurônio vencedor leva tudo” (the *winner-take-all*). Os algoritmos que utilizam este método devem se preocupar com a possibilidade de um neurônio de saída se tornar dominante e ficar ativo todo o tempo, podendo captar para si todo o espaço de entrada (BRAGA; CARVALHO; LUDERMIR, 2000). Este método é base para os mapas de Kohonen e é detalhado na próxima seção.

Cabe aqui ressaltar ainda, que para o processo de aprendizado não-supervisionado, também são utilizados outros métodos, como por exemplo: aprendizado hebbiano, modelo de Linsker, regra de Oja e regra de Yuille.

5.2 REDES DE KOHONEN

Trata-se de um método para visualização de dados complexos que fundamentalmente compõem um gráfico de similaridades a partir dos dados de entrada. Ele converte relações não-lineares dos dados de entrada em relações geométricas simples entre os pontos de sua imagem, comumente uma grade ou reticulado bidimensional. Também são encontrados, embora raramente, reticulados com mais dimensões. A grade bidimensional tem a forma de uma superfície plana, onde os neurônios de saída estão organizados em linha e colunas. Desse modo, esta ferramenta compacta a informação de entrada e preserva os relacionamentos métricos e/ou topológicos mais relevantes dos elementos primários em seu mapa, produzindo algum tipo de abstração (KOHONEN, 2001; HAYKIN, 2001).

Estes dois aspectos, visualização e abstração, podem ser utilizados em várias tarefas complexas, como: processos de análise, agrupamento (*cluster*), controle, comunicação, entre outros.

O método de redes de Kohonen também conhecido como Mapas Auto-Organizáveis ou *Self-Organizing Maps* (SOM) foi desenvolvido por Teuvo Kohonen (KOHONEN, 2001) na década de 80. O Mapa Auto-Organizável é baseado na evidência de que o cérebro é organizado em regiões que respondem a diferentes estímulos tais como fala, visão, controle motor, sensibilidade ao toque, etc. (KOHONEN, 2001). Cada uma dessas regiões contém subáreas que mapeiam internamente as respostas do órgão sensorial representado por ela (BRAGA; CARVALHO; LUDERMIR, 2000):

- Córtex auditivo: o mapeamento reflete as diferentes frequências sonoras;
- Córtex visual: o mapeamento é definido pelas características visuais primitivas, como intensidade de luz, orientação e curvatura de linhas.

Observa-se que os neurônios estão espacialmente ordenados dentro destas áreas, e, assim neurônios topologicamente próximos tendem a responder a padrões ou estímulos semelhantes.

A partir destas características biológicas, e para que a rede neural artificial se assemelhe à rede neural natural, o Mapa Auto-Organizável é concebido através de duas camadas (camada de entrada e camada de saída). Estas também são conhecidas como mapa de características (KASABOV, 1998). A conexão entre as duas camadas é feita através de um vetor de pesos sinápticos (Figura 5-7).




Figura 5-7: Mapa Auto-Organizável de características.

Observando-se a semelhança biológica, percebe-se ainda que os neurônios de saída se especializam durante o treinamento para reagirem a vetores de entrada de determinados grupos e representar características típicas compartilhadas por estes, constituindo-se regiões no reticulado de forma similar ao cérebro. Nesta camada ocorre interação lateral entre neurônios vizinhos, sendo geralmente modelada por uma função conhecida como “chapéu mexicano” (BRAGA; CARVALHO; LUDERMIR, 2000; KASABOV, 1998).

Segundo esta função, cada neurônio influencia os seus vizinhos de três formas possíveis:

- Excitatória, se os vizinhos estão próximos a ele;
- Inibitória, se os vizinhos estão fora da área anterior, mas dentro de uma segunda área;
- Levemente excitatória, se os vizinhos estão fora das áreas anteriores, mas dentro de uma terceira área.

A rede de Kohonen funciona basicamente da seguinte forma: quando um vetor de entrada é apresentado, a rede procura o neurônio mais parecido com o vetor. Durante o seu treinamento, a rede aumenta a semelhança do neurônio escolhido e de seus vizinhos ao vetor de entrada. Desta forma, a rede constrói um mapa topológico onde neurônios próximos respondem de forma semelhante a padrões de entrada com afinidade de características (BRAGA; CARVALHO; LUDERMIR, 2000).

A seguir é apresentado um detalhamento matemático deste processo.

5.2.1 Algoritmo para Mapas Auto-Organizáveis

O algoritmo responsável pela criação do mapa auto-organizável primeiramente inicia os pesos sinápticos da rede (vetor w_{ij}) utilizando valores aleatórios neste processo (inicialização randômica), ou uma inicialização linear que pode convergir o processo mais rapidamente, uma vez que este algoritmo inicializa os pesos sinápticos de forma ordenada (KOHONEN, 2001; HAYKIN, 2001). Este processo envolve ainda a definição de um modelo de

entrelaçamento do vetor que pode ser: retangular, hexagonal, ou alguma forma irregular.

O entrelaçamento hexagonal tem um melhor resultado visual (KOHONEN, 2001), pois todos os 6 vizinhos do neurônio tem a mesma distância, ao passo que no caso retangular os 8 vizinhos não tem distâncias iguais.

Após esta inicialização, ocorrem três processos essenciais na formação do mapa auto-organizável (HAYKIN, 2001):

- Competição: para cada vetor de entrada, os neurônios de saída calculam seus respectivos valores através de uma função. O neurônio com o maior valor da função é declarado o vencedor (*"the winner-take-all"*);
- Cooperação: o neurônio vencedor determina a vizinhança topológica de neurônios excitados, fornecendo assim a base para a cooperação;
- Adaptação Sináptica: este mecanismo permite que os neurônios excitados aumentem seus valores da função em relação ao padrão de entrada através de ajustes adequados aplicados a seus pesos sinápticos.

Estes processos são detalhados matematicamente nas próximas seções.

5.2.1.1 Processo Competitivo

O processo competitivo determina, dado um vetor de entrada, a função que retorna o neurônio vencedor. Segue abaixo, um dos modelos adaptado da literatura (HAYKIN, 2001; KOHONEN, 2001; VESANTO et al., 2000).

Considerando que m represente a dimensão do espaço de entrada de dados e que um vetor de entrada selecionado aleatoriamente seja representado por:

$$x = [x_1, x_2, \dots, x_m]^T \quad (5-3)$$

O mesmo está conectado em paralelo a todos os neurônios de saída através do vetor peso sináptico:

$$w_j = [w_{j1}, w_{j2}, \dots, w_{jm}]^T, \quad j = 1, 2, \dots, l \quad (5-4)$$

Sendo:

- j : neurônio de saída;
- l : número total de neurônios no reticulado.

O vetor x pode ser comparado com o vetor w_j através de várias métricas. Entre elas pode-se citar o cálculo da menor distância euclidiana para definir o neurônio vencedor, também conhecido como *best-matching node* ou *best-matching unit* (BMU), denotado na Equação 5-5 pelo subscrito c .

$$\|x - w_c\| = \min_j \{\|x - w_j\|\} \quad (5-5)$$

Caso existam variáveis em x que denotam uma maior importância, pode-se utilizar a distância euclidiana quadrática com peso através da Equação 5-6.

$$\|x - w\|^2 = \sum_{k \in K} v_k (x_k - w_k)^2 \quad (5-6)$$

Sendo:

- K : conjunto de variáveis do vetor x ;
- x_k : o k -ésimo elemento do vetor x ;
- w_k : o k -ésimo elemento do vetor w ;
- v_k : o k -ésimo elemento do vetor de pesos dos escalares do vetor x .

Após ter sido determinado o neurônio vencedor, o processo cooperativo é iniciado utilizando como centro topológico este neurônio.

5.2.1.2 Processo Cooperativo

De forma distinta, durante o processo de aprendizado cooperativo os neurônios de saída que estão topologicamente próximos, dentro de certa distância geométrica, ativarão uns aos outros para aprender alguma informação da entrada x (KOHONEN, 2001). O neurônio vencedor no processo competitivo determina o centro desta vizinhança topológica de neurônios cooperativos (HAYKIN, 2001).

Em uma formulação matemática, considera-se que h_{ci} represente a vizinhança topológica centrada no neurônio vencedor i e que contenha um conjunto de neurônios excitados (cooperativos), e que d_{ci} representa-se a distância lateral entre o neurônio vencedor i e o neurônio excitado c . Então, pode-se assumir que a vizinhança topológica $h_{ci}(t)$ é uma função unimodal (com um único ponto de máximo) da distância $d_{ci}(t)$, desde que satisfaça duas exigências (KOHONEN, 2001; HAYKIN, 2001):

- A vizinhança topológica h_{ci} é simétrica em relação ao ponto máximo definido por $d_{ci} = 0$;
- A amplitude da vizinhança topológica h_{ci} decresce monotonicamente com o aumento da distância lateral d_{ci} , decaindo a zero para $d_{ci} \rightarrow \infty$. Esta é uma condição necessária para convergência.

Algumas funções típicas que satisfazem estas condições são (VESANTO et al., 2000):

- Quadrada

$$h_{ci}(t) = 1 - \frac{d_{ci}}{\sigma_t} \quad (5-7)$$

- Gaussiana

$$h_{ci}(t) = e^{-\left(\frac{d_{ci}^2}{2\sigma_t^2}\right)} \quad (5-8)$$

- Gaussiana Truncada

$$h_{ci}(t) = e^{-\left(\frac{d_{ci}^2}{2\sigma_t^2}\right)} \cdot 1 - \frac{d_{ci}}{\sigma_t} \quad (5-9)$$

- Epanechnikov

$$h_{ci}(t) = \max\left\{0, 1 - \frac{d_{ci}^2}{\sigma_t^2}\right\} \quad (5-10)$$

Sendo:

- σ_t : largura da vizinhança topológica no tempo t ;
- d_{ci} : distância entre os neurônios c e i da camada de saída;
- t : um inteiro (tempo discreto);
- $1(x)$: função *step*, $1(x) = 0$ se $x < 0$ e $1(x) = 1$ se $x \geq 0$

Nas funções de vizinhança (Equação 5-7, 5-8, 5-9 ou 5-10), o parâmetro de largura da vizinhança topológica σ_t deverá diminuir com o tempo. Para que esta exigência seja satisfeita uma escolha comumente utilizada é o decaimento exponencial (HAYKIN, 2001).

$$\sigma_t = \sigma_0 \exp\left(-\frac{t}{T}\right) \quad (5-11)$$

Sendo:

- t : um inteiro (tempo discreto);
- σ_0 : o valor inicial da largura da vizinhança topológica (taxa de aprendizagem);
- T : é uma constante de tempo.

Após o processo de definição da vizinhança topológica, a próxima etapa realizará as modificações do vetor de peso sináptico.

5.2.1.3 Processo Adaptativo

Finalmente, o processo adaptativo (auto-organizável) implica a necessidade do vetor de peso sináptico w_j do neurônio j da grade se modificar em relação ao vetor de entrada x (HAYKIN, 2001). Este processo define o modo pelo qual esta alteração ocorre.

Kohonen (2001) propõe uma função (Equação 5-12) para alteração do peso sináptico, que é aplicada a todos os neurônios da grade que se encontram dentro da vizinhança topológica do neurônio vencedor i :

$$w_{jt+1} = w_{jt} + \eta_t h_{ci} x_t - w_{jt} \quad (5-12)$$

Sendo:

- w_{jt+1} : vetor de peso atualizado;
- t : um inteiro (tempo discreto);

- $w_j(t)$: vetor de peso sináptico;
- $\eta(t)$: parâmetro da taxa de aprendizagem do algoritmo;
- $h_{ci}(t)$: função de vizinhança topológica;
- $x(t)$: vetor de entrada.

A Equação 5-12 tem o efeito de mover o vetor peso sináptico w_j do neurônio vencedor i em direção ao vetor de entrada x (Figura 5-8).




Figura 5-8: Atualização do neurônio vencedor e da vizinhança topológica em torno do vetor de entrada x .

As linhas contínuas e pontilhadas correspondem respectivamente a situação antes e depois da atualização. (VESANTO et al., 2000).

Através da apresentação repetida dos dados de treinamento, os vetores de pesos sinápticos tendem a acompanhá-los devido à atualização da vizinhança topológica, levando desta forma o mapa de características a uma ordenação topológica. Assim sendo, neurônios adjacentes na camada de saída terão vetores de pesos sinápticos similares (HAYKIN, 2001).

A Equação 5-12 apresenta ainda o parâmetro da taxa de aprendizagem, que deve ser variável no tempo conforme indicado na mesma e monotonicamente decrescente, ou seja, deve iniciar com um valor η_0 e então decrescer gradualmente com o aumento do tempo t (KOHONEN, 2001).

Algumas funções típicas que satisfazem estas condições são (VESANTO et al., 2000):

- Linear

$$\eta_t = \eta_0 \left(1 - \frac{t}{T} \right) \quad (5-13)$$

- Exponencial

$$\eta_t = \eta_0 \left(\frac{0,005}{\eta_0} \right)^{\frac{t}{T}} \quad (5-14)$$

- Inversa

$$\eta_t = \frac{\eta_0}{\left(1 + 100 \frac{t}{T} \right)} \quad (5-15)$$

- Decaimento Exponencial (HAYKIN, 2001)

$$\eta_t = \eta_0 \exp \left(- \frac{t}{T} \right) \quad (5-16)$$

Sendo:

- η_0 : valor inicial da taxa de aprendizagem;
- t : um inteiro (tempo discreto);
- T : é uma constante de tempo.

Na Figura 5-9, são apresentadas as quatro funções de taxa de aprendizagem com os respectivos gráficos (VESANTO et al., 2000):

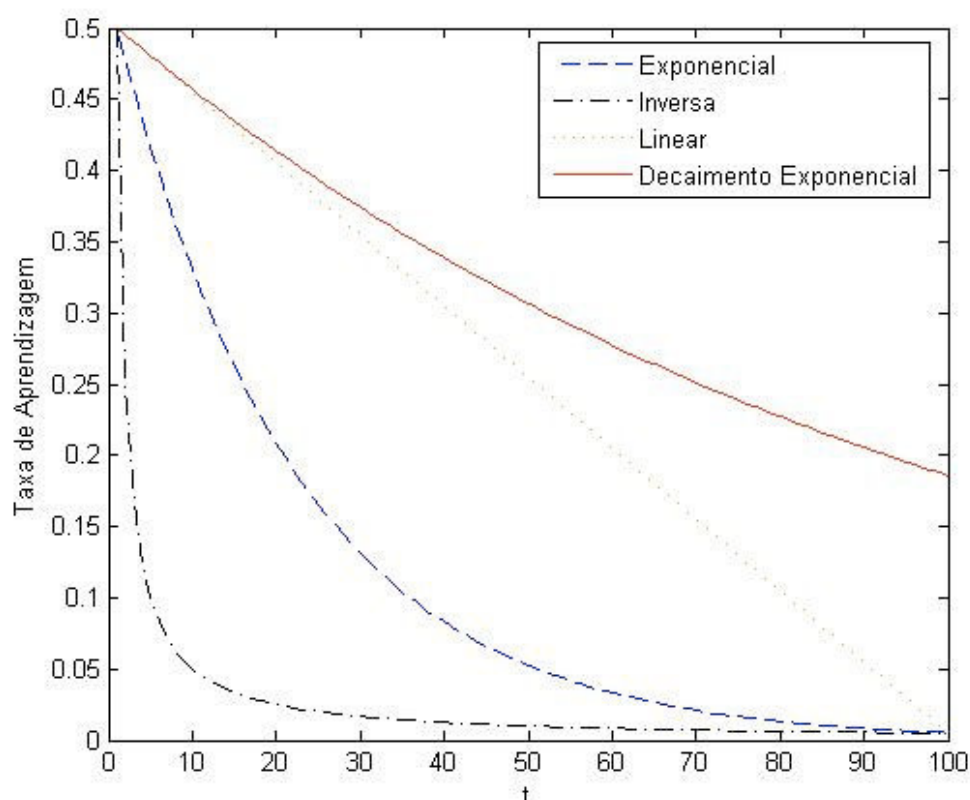


Figura 5-9: Funções de taxas de aprendizagem: Linear, Exponencial, Inversa e Decaimento Exponencial, com $\eta_0=0,5$ e $T=100$.

A taxa de aprendizagem presente neste processo adaptativo e a função de vizinhança apresentada no processo cooperativo devem ser definidas de forma cuidadosa utilizando-se valores de acordo com a fase adaptativa em execução: ordenação ou convergência (HAYKIN, 2001). No entanto, escolhas eficazes para estas funções e seus parâmetros só são possíveis de serem determinadas experimentalmente (KOHONEN, 2001).

Na fase de ordenação ou auto-organização é realizada a ordenação topológica dos vetores de peso. Comumente a fase de ordenação exige 1000 iterações ou mais do algoritmo para Mapas Auto-Organizáveis. Segundo Haykin (2001), nesta fase a taxa de aprendizagem deve iniciar com um valor próximo de 0,1 e decrescer gradualmente, não diminuindo de 0,01.

A função de vizinhança deve inicialmente incluir quase todos os neurônios da grade centrados no neurônio vencedor i , e então diminuir lentamente com o tempo. Levando em consideração a grade bidimensional de

neurônios, o tamanho inicial σ_0 desta função deverá igualar-se ao “raio” da grade.

Na segunda fase, ou fase de convergência é realizada um refinamento do mapa de características para uma adequada precisão estatística. Como regra geral, o número de iterações desta fase deve ser da ordem de 500 vezes o número de neurônios da camada de saída. Deste modo, o número de iterações pode ser da ordem de dezenas ou centenas de milhares, contudo este algoritmo pode ser considerado computacionalmente leve. A quantidade de dados de entrada x não tem efeito no número de iterações, e caso não tenha muitos exemplos disponíveis, estes valores devem ser reutilizados para o número de iterações desejadas (KOHONEN, 2001).

Haykin (2001) especifica que nesta fase a taxa de aprendizagem η_0 deve ser mantida em um valor pequeno próximo de 0,01. Segundo este autor a taxa não deve ser diminuída a zero para que não ocorra um defeito topológico no mapa, conhecido como estado metaestável. A função de vizinhança h_{ci} deve ser reduzida somente aos neurônios bem próximos, eventualmente chegando a um ou a zero neurônio vizinho.

5.2.2 Estrutura do algoritmo de Kohonen

Conforme apresentado anteriormente, o algoritmo de Kohonen pode sofrer alterações matemáticas para otimizar o resultado em um determinado trabalho. No entanto, de forma sintética, o algoritmo é composto das seguintes etapas (KASABOV, 1998):

1. *Inicialização*: Define valores aleatórios e pequenos para os vetores de peso iniciais $w_j(0)$, para todo neurônio j da grade de saída;
2. *Amostragem*: Aplica a grade um vetor x do espaço de entrada;
3. *Similaridade*: Encontra o neurônio i através do critério de mínima distância euclidiana entre o vetor de entrada x e o vetor de peso $w_j(t)$ para cada neurônio j , usando a seguinte fórmula:

$$\|x - w_c\| = \min_j \{\|x - w_j\|\} \quad (5-17)$$

4. *Atualização*: Ajusta todos os vetores de peso sináptico dos neurônios da grade que se encontram dentro da vizinhança topológica do neurônio vencedor i :

$$w_{ji}(t+1) = w_{ji}(t) + \eta(t) h_{ci}(x(t)) w_{ji}(t) \quad (5-18)$$

5. *Continuação*: Continua com o passo 2 até que não sejam observadas modificações significantes no mapa de características.

Haykin (2001) observa que este algoritmo, a partir de uma desordem completa, gradualmente leva a uma representação organizada de padrões de ativação retirados do espaço de entrada, desde que os parâmetros sejam selecionados adequadamente.

No próximo capítulo é apresentada uma ferramenta para implementação da rede, bem como os passos iniciais deste processo.

6 IMPLEMENTAÇÃO DE MAPAS AUTO-ORGANIZÁVEIS PARA CLUSTERIZAÇÃO DE OBJETOS DE APRENDIZAGEM

Neste capítulo, são apresentadas as ferramentas utilizadas neste trabalho (MATLAB e o *SOM Toolbox*) para a definição da rede de Kohonen e como elas interagem com a rede nas fases de pré-processamento, inicialização, treinamento, visualização e análise. É abordada também nesta seção a formação dos dados de entradas utilizando-se da tabela de avaliação.

O desenvolvimento da Rede de Kohonen para clusterização de objetos de aprendizagem pauta-se na utilização do software MATLAB versão 7 juntamente com o *SOM Toolbox 2.0*. Kohonen (2001) apesar de considerar importante o processo de aprendizagem de um algoritmo através da programação do mesmo, recomenda a utilização de um pacote pronto e testado de software para Mapas Auto-Organizáveis, como é o caso do *SOM Toolbox*, devido à necessidade de experimentações para definição de parâmetros.

O MATLAB, desenvolvido pela MathWorks Inc., é um ambiente de programação extensamente utilizado para computação técnica e possui versões para diferentes sistemas operacionais como Windows e várias plataformas de Unix (VESANTO et al., 2000). Ele possui uma linguagem de alto nível e um ambiente interativo para o desenvolvimento de algoritmos, visualização e análise de dados, e para a computação numérica. Esta estrutura destina-se a um amplo número de aplicações, dentre as quais incluem-se o processamento de sinais e imagem, comunicação, controles, testes e medidas, modelo financeiro e biologia computacional.

Através de complementos, conhecidos como *Toolbox*, é possível ampliar o MATLAB para resolver classes de problemas particulares em diversas áreas. Para aplicações de Mapas Auto-Organizáveis, existe o *SOM Toolbox* que pode ser utilizado no pré-processamento dos dados de entrada, na inicialização, no treinamento (usando diferentes tipos de topologias), na visualização e na análise das propriedades e dos dados dos Mapas Auto-Organizáveis (VESANTO et al., 2000). Este Toolbox é disponibilizado de forma gratuita na Internet pelo *Department of Computer Science and Engineering* da *Helsinki University of Technology* através da licença GNU (*General Public License*).

Do ponto de vista estrutural, sua utilização é dividida em quatro partes distintas (VESANTO et al., 2000):

- **Leitura dos dados de entrada** – a disponibilização dos dados de entrada é realizada através de uma tabela única, que contém os dados numéricos para as variáveis. Cada linha da tabela corresponde a uma amostra dos dados analisados e cada coluna corresponde às propriedades do objeto (variáveis observadas), ou a um conjunto de medições em um determinado momento (Figura 6-1). Nesta estrutura, alguns valores das propriedades podem estar faltando, desde que a maioria esteja presente. Estes dados são, então, carregados para o MATLAB através de comandos do *SOM Toolbox*.

	1ª variável	2ª variável	3ª variável	4ª variável
1ª amostra →				
2ª amostra →				
3ª amostra →				
4ª amostra →				
Etc.				

Figura 6-1: Formato da tabela de dados. A estrutura pode ter qualquer número de amostras, no entanto todas as amostras devem ter o mesmo número de variáveis e com o mesmo significado.
(VESANTO et al., 2000)

- **Pré-processamento dos dados** – envolve o processo de simples transformação ou normalização realizada sob as variáveis. Contudo, é relevante ressaltar que, como o algoritmo para Mapas Auto-Organizáveis utiliza a métrica euclidiana para medir a distância entre vetores esta etapa é determinante para a utilização desta ferramenta. Pois, se o espaço de uma variável estiver entre $[0, \dots, 1000]$ e de outra estiver entre $[0, \dots, 1]$, a

primeira irá dominar completamente o mapa, dificultando a análise do mesmo.

- **Inicialização e Treinamento** – Existem dois algoritmos de inicialização (randômica e linear) e dois de treinamento (seqüencial e lote) implementados nesta ferramenta. Neste sentido, o treinamento é realizado em duas fases. A primeira é realizada com um raio de vizinhança e taxa de aprendizagem relativamente maiores do que os valores utilizados na segunda fase.
- **Visualização e Análise** – existem várias funções para visualização do Mapa Auto-Organizável. Estas estão divididas em:
 - **Visualização de células**, que mostra o estado de saída do reticulado;
 - **Visualização de gráficos**, que apresenta um reticulado com gráficos simples em cada unidade do mapa.

Como visto anteriormente, a primeira etapa refere-se à leitura dos dados de entrada contidos em uma tabela. Para tanto, esta tabela de entrada foi constituída da seguinte forma:

- **Parâmetros de contextualização:** enumeração do domínio do conhecimento dos OAs que estão sendo avaliados e compõem um ROA.
- **Parâmetros de avaliação:** enumeração dos itens de avaliação apresentados no capítulo 3 deste trabalho.

O primeiro grupo de itens foi criado a partir da adaptação da Tabela das Áreas de Conhecimento⁴, cuja estrutura é baseada em uma estrutura hierárquica de quatro níveis, conforme Figura 6-2.

⁴ URL: <http://www.capes.gov.br/avaliacao/tabelaareasconhecimento.html>

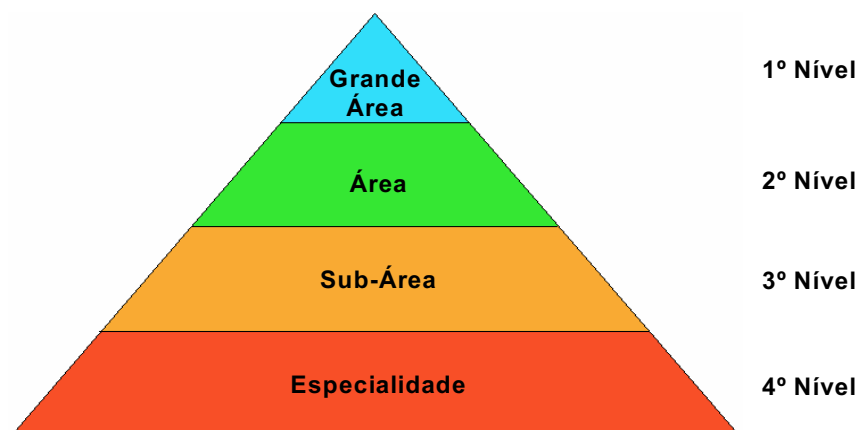


Figura 6-2: Estrutura hierárquica da Tabela das Áreas de Conhecimento.

Nesta estrutura, a Grande Área, é subdividida em oito grupos, conforme abaixo:

- Ciências Exatas e da Terra;
- Ciências Biológicas;
- Engenharias;
- Ciências da Saúde;
- Ciências Agrárias;
- Ciências Sociais Aplicadas;
- Ciências Humanas;
- Linguística, Letras e Artes.

A Grande Área escolhida como amostra para a elaboração desta pesquisa é a de Ciências Exatas e da Terra, detalhada a seguir:

- **Matemática**
 - Álgebra
 - Análise
 - Geometria e Topologia
 - Matemática Aplicada
- **Probabilidade e estatística**
 - Probabilidade
 - Estatística

- Probabilidade e Estatística Aplicadas
- **Física**
 - Física Geral
 - Áreas Clássicas de Fenomenologia e suas Aplicações
 - Física das Partículas Elementares e Campos
 - Física Nuclear
 - Física Atômica e Molecular
 - Física dos Flúidos, Física de Plasmas e Descargas Elétricas
 - Física da Matéria Condensada
- **Oceanografia**
 - Oceanografia Biológica
 - Oceanografia Física
 - Oceanografia Química
 - Oceanografia Geológica

Dentre as áreas e sub-áreas apresentadas, este trabalho foi direcionado à área de Matemática e à sub-área de Álgebra. Desta forma, a configuração básica da tabela de entrada de dados possui a estrutura apresentada na Figura 6-3.




Figura 6-3: Formação da tabela de dados de entrada da Rede de Kohonen.

Tomando como base esta estrutura, foi criada a Tabela de Objetos de Aprendizagem Avaliados (Anexo B), que enumera propriedades relevantes para a construção da rede neural, conforme discutido em capítulos anteriores. Os OAs que formam a amostra desta pesquisa foram selecionados nos repositórios (Anexo A) a partir de palavras-chave relacionadas à sub-área de Álgebra.

A segunda fase, realizada após o levantamento dos dados de entrada (descrita no início deste capítulo), seria a realização da normalização na fase de pré-processamento do Mapa Auto-Organizável. Contudo, como o espaço dos dados do presente estudo está delimitado entre $[0...10]$ para todas as variáveis, não foi necessária a realização desta fase.

Após esta etapa, o Mapa Auto-Organizável foi inicializado para a realização do treinamento, o que possibilitou a extração de resultados do mapa⁵. A partir da análise destes é possível extrair informações qualitativas do mapa, bem como analisar os agrupamentos criados. Neste processo uma alternativa é utilizar apresentações gráficas. O modelo de entrelaçamento gráfico escolhido neste trabalho foi o hexágono.

É passível de utilização também para análise, resultados numéricos que apresentem: ocupação dos neurônios no Mapa Auto-Organizável e taxas de erros⁶.

Visto a estruturação dos dados de entrada, bem como o funcionamento do *SOM Toolbox* no MATLAB, no próximo capítulo, são apresentados os resultados obtidos primeiramente com um espaço amostral reduzido para a definição de uma metodologia e da máscara de pesos. Em seguida é aplicada a mesma metodologia para o conjunto de 80 OAs (disponíveis no Anexo B) para a estruturação do Mapa Auto-Organizável.

⁵ O modo de inicialização e os algoritmos de treinamentos são discutidos no próximo capítulo.

⁶ As análises numéricas são detalhadas no próximo capítulo.